

UFC FIGHT PREDICTOR · DIO 1 OD 4

Podaci koje koristimo

Jednostavno objašnjenje: šta imamo, šta je dobro, šta nedostaje, i šta smo morali izbaciti prije nego što računar bilo šta nauči.

Septembar 2026 · Napisano jednostavnim jezikom, bez tehničkih termina

0. O čemu je ovaj dokument

Prije nego što napravimo bilo kakvu predikciju, moramo dobro razumjeti podatke koje imamo. Ovaj dokument odgovara na tri pitanja:

- **Šta tačno imamo?** — dva fajla: jedan o borcima, jedan o mečevima.
- **Šta je u njima dobro, a šta problematično?** — neki podaci nedostaju, neki se ne mogu koristiti onako kako izgledaju.
- **Šta smo morali izbaciti ili popraviti, i zašto?**

Nema formula ni statistike u ovom dokumentu — to dolazi kasnije, u dijelu 2 i 3. Ovdje je fokus samo na pitanju: *da li su nam podaci uopšte dobra polazna tačka?*

1. Fajl broj 1 — "Lične karte" boraca

Ovaj fajl (ufc_fighters_final.csv) je kao kartoteka: **4455** boraca, po jedan red za svakog, sa njihovim ličnim i karijernim podacima.

Koje kolone imamo i šta znače

Kolona u fajlu	Šta to znači (jednostavno)
Fighter_Name	Ime i prezime borca
Height	Visina
Weight	Težina
Reach	Raspon ruku — koliko daleko borac dosegne rukom (bitno za udaranje na distanci)
Stance	Borilački stav — npr. "Orthodox" (klasičan, desnoruk) ili "Southpaw" (ljevoruk)
DOB	Datum rođenja
Wins / Losses / Draws	Pobjede / Porazi / Neriješeni mečevi (ukupno u karijeri)
SLpM	Koliko udaraca u prosjeku zadaje po minuti borbe
Str_Acc	Koliki postotak njegovih udaraca zapravo pogodi metu
SAPM	Koliko udaraca u prosjeku <i>primi</i> od protivnika po minuti
Str_Def	Koliko dobro blokira/izbjegava protivničke udarce (postotak)
TD_Avg	Koliko puta u prosjeku obori protivnika na tlo (takedown)
TD_Acc	Koliki postotak pokušaja obaranja mu uspije
TD_Def	Koliko dobro brani od toga da NJEGA obore na tlo
Sub_Avg	Koliko puta u prosjeku pokuša "submission" (tehniku predaje)

Šta je dobro, a šta nedostaje

Provjerili smo koliko je od 4455 boraca ima popunjen svaki podatak:

Datum rođenja		89% ima
Visina		93% ima
Stav (Stance)		81% ima
Raspon ruku (Reach)		56% ima

Drugim riječima: skoro **polovini boraca (44%) nedostaje podatak o rasponu ruku**, a **svakom petom borcu (19%) nedostaje podatak o stavu**. Kad podatak nedostaje, u tabeli je jednostavno prazno polje.

✓ Kako smo ovo riješili (bez brisanja boraca)

Umjesto da izbacimo skoro polovinu boraca (što bi bilo preveliki gubitak), procijenili smo nedostajuće vrijednosti na pametan način:

- **Raspon ruku**

— viši ljudi skoro uvijek imaju i veći raspon ruku (ova dva podatka su usko povezana). Kad raspon ruku nedostaje, procijenimo ga na osnovu borčeve visine.

- **Visina**

— kad nedostaje, uzmemo prosječnu visinu boraca iz iste težinske kategorije (npr. teškaši su u prosjeku viši od boraca slamnate kategorije).

- **Stav**

— ovdje ne "izmišljamo" podatak, nego jednostavno označimo borca kao "stav nepoznat", i to tretiramo kao posebnu, validnu kategoriju.

Svaki put kad procijenimo vrijednost, obilježimo je posebnom "zastavicom" da računar zna da je to procjena, a ne stvarno izmjeren podatak.

Primjer: ako borcu nedostaje raspon ruku, a visok je 180 cm, sistem će mu dodijeliti procijenjeni raspon ruku sličan drugim borcima te visine — umjesto da ga potpuno izbacimo iz analize.

2. Fajl broj 2 — "Izvještaji" o mečevima

Ovaj fajl (`ufc_gold_dataset_final.csv`) sadrži **8551** odigranih UFC mečeva, od 1994. do danas — jedan red po meču, sa detaljima o tome šta se desilo.

Koje kolone imamo i šta znače

Kolona u fajlu	Šta to znači (jednostavno)
Fighter_1, Fighter_2	Imena dva borca koja su se sukobila
Winner	Ko je pobijedio
Weight_Class	Težinska kategorija tog meča
Method	Kako se meč završio — nokaut (KO/TKO), predaja (Submission) ili odluka sudija (Decision)
End_Round, End_Time	U kojoj rundi i minuti se meč završio
F1_Sig_Landed, F2_Sig_Landed	Koliko je svaki borac zadao pogođenih udaraca u tom konkretnom meču
F1_TD_Landed, F2_TD_Landed	Koliko je svaki borac izveo uspješnih obaranja u tom meču
F1_Ctrl_Sec, F2_Ctrl_Sec	Koliko sekundi je svaki borac kontrolisao protivnika na tlu u tom meču
... (još desetak sličnih kolona)	Sve su to detaljne brojke o tome šta se desilo tokom tog konkretnog meča

⚠ Najvažnija stvar u cijelom dokumentu

Kolone koje opisuju šta se desilo

tokom meča

(koliko je udaraca zadato, koliko obaranja itd. u TOM meču)

ne smijemo koristiti

da predviđamo ishod tog istog meča. To bi bila varanje.

Zamisli da pokušavaš predvidjeti hoće li sutra padati kiša, ali kao podatak koristiš "koliko je kiše stvarno palo sutra". To nema smisla — sutra se još nije desilo u trenutku kad praviš predikciju. Isto je i ovdje: kad predviđamo budući meč, ne znamo unaprijed koliko će udaraca ko zadati u tom meču — to je upravo ono što pokušavamo pogoditi.

✓ Kako ipak koristimo te brojeve (na pravi način)

Iste te brojke

iz ranijih, već odigranih mečeva

tog borca su potpuno korisne i dozvoljene. Ako borac ima 10 mečeva iza sebe, možemo pogledati "u prosjeku, koliko je udaraca zadavao u svojim prethodnih 10 mečeva" — to opisuje njegovu formu i stil, i to stvarno znamo unaprijed, prije 11. meča. To je ono što zapravo koristimo za predikciju (detaljnije u dijelu 2 ovog serijala dokumenata).

Šta smo morali izbaciti i zašto

Od 8551 mečeva, **174 meča (2%) smo izbacili** jer nisu imali jasan, "čist" ishod:

Razlog izbacivanja	Broj mečeva	Zašto to nije koristan podatak
Neriješeno / meč poništen (Draw / No Contest)	151	Nema pobjednika — ne možemo naučiti "ko je bolji" iz meča koji nema pobjednika
Odluka poništena naknadno (Overturned)	58	Rezultat je promijenjen administrativnom odlukom, ne u samoj borbi
Meč nije mogao biti nastavljen (povreda, itd.)	32	Ishod ne odražava ko je bio bolji borac te večeri
Diskvalifikacija (DQ)	23	Pobjeda zbog prekršaja pravila, ne zbog nadmoći u borbi
Ostalo	2	Rijetki, nejasni slučajevi

(Napomena: brojevi se malo preklapaju — npr. jedan meč može istovremeno biti i "poništen" — pa ukupan zbir kategorija nije tačno 174, ali ukupno izbačenih je 174.)

Sredili smo i "kategorije" (težinske klase)

U sirovim podacima postojalo je **123 različita naziva** za težinsku kategoriju — ali mnogi znače potpuno istu stvar. Na primjer, "Lightweight Bout" i "UFC Lightweight Title Bout" su OBA jednostavno "Lakoteška kategorija" — razlika je samo u tome da je drugi bio meč za titulu.

Sveli smo sve to na **15 standardnih kategorija** (npr. Bantamweight, Lightweight, Heavyweight, Women's Strawweight...), plus posebnu oznaku "ovo je bio meč za titulu" kad je to slučaj. Tako je podatak čist i jasan za dalju upotrebu.

3. Sažetak — šta smo naučili o podacima

Pitanje	Odgovor
Koliko boraca imamo?	4455
Koliko mečeva imamo (nakon čišćenja)?	8377 od originalnih 8551
Koji podatak najviše nedostaje?	Raspon ruku (Reach) — nedostaje kod 44% boraca, ali smo ga uspješno procijenili
Šta se ne smije koristiti direktno?	Brojevi "šta se desilo u meču" ne smiju se koristiti za predikciju TOG ISTOG meča — samo iz RANIJIH mečeva
Šta smo izbacili?	174 meča bez jasnog pobjednika (neriješeno, poništeno, diskvalifikacija)
Da li su podaci sada spremni za pravljenje predikcija?	DA — nakon čišćenja i procjene nedostajućih vrijednosti

Šta slijedi u sljedećem dokumentu

U drugom dokumentu ćemo objasniti — i dalje jednostavnim jezikom — *kako* tačno računar koristi ove podatke da "nauči" praviti predikcije, i zašto smo neke stvari morali posebno pažljivo pripremiti.