

UFC FIGHT PREDICTOR · DIO 3 OD 4

Tri modela i kako svaki "razmišlja"

Bez formula: tri različita pristupa koja koristimo da napravimo predikciju, objašnjena kroz analogije koje svako može razumjeti.

Septembar 2026 · Nastavak na Dio 2 (Kako računar uči)

0. Zašto tri modela, a ne samo jedan

U Dijelu 2 smo objasnili kako svaki meč pretvaramo u "karticu" sa oko 28 poređenja između dva borca. Sad dolazi ključno pitanje: **šta konkretno radi s tom karticom da bi napravilo predikciju?**

Umjesto da se oslonimo na samo jedan pristup, koristimo **tri različita "načina razmišljanja"** — od najjednostavnijeg do najsloženijeg. Razlog je jednostavan: nijedan pristup nije univerzalno najbolji za svaki problem, pa je poštenije isprobati nekoliko i uporediti ih (rezultati tog poređenja su tema Dijela 4).

1. Logistička regresija

najjednostavniji, kao formula



2. Random Forest

"vijeće" od stotine mini-sudija



3. LightGBM

tim koji uči na greškama, iznova i iznova

1. Logistička regresija — "formula bodovanja"

MODEL 1 - NAJJEJEDNOSTAVNIJI

Zamisli da svakom poređenju sa "kartice" (razlika u godinama, u nizu pobjeda, u prosjeku udaraca...) dodijeliš određenu **težinu** — koliko je taj podatak bitan. Zatim sve pomnožiš sa svojom težinom i sabereš u jedan ukupan zbir. Što je zbir veći, to je veća vjerovatnoća da pobjeđuje Borac A.

Analogija: odobravanje kredita u banci

Banka kad odlučuje da li da ti odobri kredit, boduje razne faktore — platu, kreditnu istoriju, staž na poslu — svaki sa svojom "težinom", pa sabere ukupan skor. Ako je skor iznad neke granice, kredit se odobrava. Logistička regresija radi potpuno isto: računar sam, gledajući hiljade starih mečeva, odredi **koliko je "teška"** svaka pojedina razlika (npr. otkrije da je razlika u godinama vrlo "teška", a razlika u visini gotovo "lagana" — vidjeli smo to i u konkretnom primjeru u Dijelu 2).

✓ **Prednost** Vrlo lako je objasniti tačno ZAŠTO je model nešto zaključio — samo pogledaš koje su težine najveće. Transparentan i brz.

✗ **Mana** Pretpostavlja da svaki faktor "vuče" uvijek u istom pravcu, bez obzira na ostale. Teže hvata situacije tipa "ovo je bitno SAMO kada se poklopi sa nečim drugim".

Primjer u brojkama: Jon Jones vs. Alex Pereira (isti par kao u Dijelu 2)

Ovo su **stvarni bodovi** koje je istrenirani model dodijelio svakoj razlici sa "kartice" za ovaj konkretan meč (crveno = gura ka pobjedi Jonesa, sivo = gura ka pobjedi Pereire):

Niz pobjeda		+1.18 (Jones)
Broj pobjeda do sada		+0.73 (Jones)
Težina		+0.25 (Jones)
Prosjek obaranja		+0.20 (Jones)
Raspon ruku		+0.20 (Jones)
Broj poraza do sada		+0.18 (Jones)
Vrijeme kontrole		-0.17 (Pereira)

Kad se svi bodovi (uključujući i one manje bitne, van liste) sabere, ukupan zbir odgovara **93.7% šanse da pobijedi Jon Jones** — što se poklapa sa stvarnom predikcijom aplikacije iz Dijela 2. Primijeti kako "niz pobjeda" nosi ubjedljivo najviše bodova, tačno kao što smo vidjeli u analizi važnosti podataka (Dio 4).

2. Random Forest — "vijeće od 300 mini-sudija"

MODEL 2 · GRUPNO ODLUČIVANJE

Ovaj pristup ne pravi jednu formulu, nego kreira **300 nezavisnih "mini-sudija"**. Svaki mini-sudija gleda samo dio kartice (nasumično odabrane podatke) i donosi svoju odluku postavljajući niz jednostavnih pitanja — "Da li je razlika u godinama veća od 5? Ako da, pitaj dalje ovo, ako ne, pitaj ono drugo..." — sve dok ne dođe do zaključka. Na kraju se sakupe odluke svih 300 mini-sudija i pobjeđuje ono što je većina rekla.

Analogija: žiri od 300 ljudi

Zamisli takmičenje gdje umjesto jednog sudije glasa 300 ljudi, i svako gleda malo drugačiji ugao problema. Pojedinačno, neki od njih mogu pogriješiti, ali kad se uzme glasanje cijele grupe, rezultat je obično pouzdaniji nego mišljenje samo jedne osobe.

✓ **Prednost** Bolje hvata složene kombinacije faktora (npr. "mlad borac SA dobrim nizom pobjeda je posebno opasan" — kombinacija dva faktora zajedno).

✗ **Mana** Teže je objasniti tačno zašto je odlučio baš tako (300 "glasova" je teško ručno pratiti). Kao što ćemo vidjeti u Dijelu 4, njegovo "glasanje" ponekad zna biti neopravdano jednostrano — praktično uvijek glasa za najčešću opciju, čak i kad to nije najbolja procjena.

Primjer u brojkama: Jon Jones vs. Alex Pereira

Pustili smo isti par kroz svih 300 mini-sudija pojedinačno i prebrojali njihove glasove:

230 glasova za Jonesa • **70 glasova** za Pereiru



■ glasao za Jonesa ■ glasao za Pereiru (svaki kvadrat = 10 mini-sudija)

$230/300 = 76.7\%$ — to je tačno vjerovatnoća koju ovaj model prijavljuje za pobjedu Jonesa. Za razliku od Logističke regresije (93.7%), Random Forest je ovdje malo "opreznije" siguran — ali oba modela se slažu da je Jones favorit.

3. LightGBM — "tim koji uči na svojim greškama"

MODEL 3 · NAJSLOŽENIJI

Ovaj pristup radi u krugovima. Prvi "pokušaj" napravi grubu, jednostavnu procjenu za sve mečeve odjednom. Zatim se pogleda **gdje je taj pokušaj najviše pogriješio**, i sljedeći "pokušaj" se fokusira baš na popravljane tih grešaka. Treći pokušaj ispravlja ono što je drugi propustio, i tako dalje — u našem slučaju, ovo se ponavlja 300 puta. Konačna odluka je zbir svih tih malih, postepenih popravki.

Analogija: tim ljekara koji redom pregledaju pacijenta


Prvi ljekar da grubu, početnu dijagnozu. Drugi ljekar se fokusira baš na simptome koje je prvi možda pogrešno protumačio. Treći ispravlja ono što su prva dva propustila. Svaki sljedeći se ne bavi cijelim slučajem iznova — samo popravljja greške prethodnih. Krajnja dijagnoza je zbir svih tih postepenih popravki.

✓ **Prednost** Često daje najbolji balans između toga da bude tačan i da pošteno priznaje koliko je siguran u svoju procjenu (npr. kad kaže "70% siguran", to stvarno treba da znači tačno u otprilike 70% takvih slučajeva — više o ovome u Dijelu 4).

✗ **Mana** Najsloženiji od sva tri — najteže je "ručno" provjeriti logiku iza pojedinačne odluke. Zahtijeva i najviše pažnje da se ne "pretjera" u učenju (previše krugova popravki na malom broju podataka može dovesti do toga da model "nauči napamet" umjesto da stvarno razumije obrazac).

Primjer u brojkama: Jon Jones vs. Alex Pereira

Ovdje se lijepo vidi sama ideja "popravki iznova i iznova" — pratili smo kako se procjena mijenja kako model dodaje sve više krugova popravki (stabala):



Nakon samo 1 stabla, procjena je gotovo čisto nagađanje (50.7%) — model tek počinje. Svaki sljedeći krug popravki gura procjenu sve više prema stvarnom zaključku, dok se nakon svih 300 krugova ne "smiri" na konačnih **92.0% šanse za pobjedu Jonesa** — vrlo blizu procjeni Logističke regresije (93.7%) i Random Forest-a (76.7%).

4. Kako provjeravamo koji je model zapravo dobar

Nije dovoljno da model kaže "ja sam tačan" — moramo to nezavisno provjeriti, na pravi, pošten način.

Analogija: pravi ispit, ne "prepisivanje"

Zamisli učenika koji uči iz udžbenika sa 100 zadataka. Ako ga na ispitu pitaš baš te iste zadatke, naravno da će sve tačno riješiti — ali to ne dokazuje da *razumije* gradivo, samo da ih je zapamtio. Pravi test znanja je da ga pitaš **novе zadatke koje nikad prije nije vidio**, ali koji su iz iste oblasti.

Mi radimo potpuno isto: od svih 16 754 "primjera za učenje" (iz Dijela 2), model trenirama samo na **80% mečeva** ("udžbenik") — preostalih **20% mečeva** ("ispit") sistem tokom učenja nikad ne vidi. Tek na kraju ga testiramo na tih 20% i gledamo koliko je stvarno pogodilo.

⚠ Pažljivo s "blizancima" iz Dijela 2

Sjeti se — svaki meč u podacima postoji dvaput (original + zamijenjene strane, iz Dijela 2 poglavlja 3). Pobrinuli smo se da obje verzije ISTOG meča uvijek završe zajedno — ili obje u "udžbeniku", ili obje na "ispitu", nikad razdvojene. Kad ne bismo pazili na ovo, model bi mogao "prepoznati" svog blizanca s ispita i lažno izgledati pametnije nego što jeste.

✓ Dvostruka provjera radi sigurnosti

Da budemo još sigurniji, radimo ovu podjelu na "udžbenik/ispit"

5 puta

, svaki put s drugačijom nasumičnom podjelom, i gledamo da li model dosljedno postiže sličan rezultat u svih 5 pokušaja. Ako rezultat mnogo skače od pokušaja do pokušaja, to je znak da mu ne možemo baš vjerovati — u Dijelu 4 ćemo vidjeti da su naši modeli prilično dosljedni.

5. Zašto ti u aplikaciji možeš birati model

Pošto se pokazalo (Dio 4) da nijedan od ova tri pristupa nije "pobjednik u svemu" — svaki ima svoje prednosti zavisno od pitanja koje postavljaš (ko pobjeđuje, ili kako se meč završava) — odlučili smo da ti damo izbor umjesto da ti nametnemo samo jedan model. U aplikaciji možeš isprobati sva tri i uporediti njihove predikcije za isti meč.

6. Sažetak

Model	Kako razmišlja (jednom rečenicom)	Glavna prednost
Logistička regresija	Sabere "otežane" razlike u jedan zbir	Transparentan, lako objasniti zašto
Random Forest	300 mini-sudija glasa, pobjeđuje većina	Hvata složenije kombinacije faktora
LightGBM	Stotine krugova postepenih popravki grešaka	Najbolji balans tačnosti i poštenog priznavanja nesigurnosti

Pitanje	Odgovor
Kako provjeravamo da model stvarno "razumije", a ne samo "pamti"?	Testiramo ga na 20% mečeva koje nikad nije vidio tokom učenja
Zašto ponavljamo provjeru 5 puta?	Da vidimo da li je rezultat dosljedan, ne samo "srećan pokušaj"
Zašto nudimo izbor između tri modela u aplikaciji?	Nijedan nije univerzalno najbolji — zavisi od pitanja (vidi Dio 4)

Šta slijedi u sljedećem, posljednjem dokumentu

U Dijelu 4 konačno pokazujemo *stvarne rezultate* — koliko je svaki model tačan, gdje griješi, i jedan iznenađujući nalaz: model sa "najboljom ocjenom" nije uvijek i najkorisniji.