

UFC FIGHT PREDICTOR · DIO 4 OD 4

Rezultati: šta radi dobro, šta ne, i zašto

Posljednji dio serijala: stvarni brojevi, i jedno iznenađujuće otkriće — model koji izgleda "najbolje" na papiru nije uvijek i najkorisniji.

Septembar 2026 · Nastavak na Dio 3 (Modeli)

0. Dva pitanja, dva različita stepena težine

Podsjetnik: aplikacija odgovara na **dva odvojena pitanja** za svaki meč:

- **Ko pobjeđuje?** — Borac A ili Borac B
- **Kako se meč završava?** — nokaut (KO/TKO), predaja (Submission), ili odluka sudija (Decision)

Testirali smo sva tri modela na **3352 meča koje nikad nisu vidjeli tokom učenja** (pravi "ispit", objašnjeno u Dijelu 3). Kao što ćemo vidjeti, ova dva pitanja nisu podjednako teška — i tu leži najvažnija lekcija cijelog dokumenta.

1. Rezultati — "Ko pobjeđuje?"

Pošto smo (iz Dijela 2) osigurali da je tačno pola test-mečeva "Borac A pobjeđuje" a pola "Borac B pobjeđuje", **čisto nagađanje bi pogodilo tačno 50%** — to nam je polazna linija za poređenje.

62.7%

Logistička regresija

61.7%

Random Forest

60.7%

LightGBM

(Tačnost na 3352 meča koje modeli nikad nisu vidjeli. Čisto nagađanje = 50%.)

✓ Nalaz: sva tri su bolja od nagađanja, a najjednostavniji je najbolji

Logistička regresija (Dio 3, "formula bodovanja") je — pomalo iznenađujuće — najtačnija za ovo pitanje. To sugerise da je pitanje "ko je bolji borac" prilično *pravolinijski* problem: stariji/iskusniji/u boljoj formi borac generalno pobjeđuje otprilike proporcionalno razlici, bez potrebe za "višećem" ili "timom koji uči na greškama".

Koliko možemo vjerovati kad model kaže "X% siguran"?

Šta znači "pošteno" priznavanje sigurnosti

Zamisli da model kaže "Borac A ima 80% šanse da pobijedi". Ako pogledamo SVE mečeve gdje je bilo koji model rekao otprilike "80% siguran", i Borac A se stvarno pojavio kao pobjednik u oko 80 od 100 takvih mečeva — model je pošten prema svojoj vlastitoj sigurnosti. Ako bi se pobjednik pojavio u samo, recimo, 55 od 100 takvih slučajeva, model bi bio **previše samouvjeren** — kaže da je siguran, a zapravo nije toliko.

I po ovom mjerilu, Logistička regresija je opet najbolja — njeni procenti pouzdanosti najviše odgovaraju stvarnosti. Random Forest i LightGBM su malo "preambiciozniji" u svojim procjenama.

Šta najviše utiče na to ko pobjeđuje

Pogledali smo koji podaci sa "kartice" (Dio 2) najjače razdvajaju pobjednike od gubitnika:

Razlika u godinama		najjače
Trenutni niz pobjeda		jako
Prosjek obaranja protivnika		jako
Prosjek vremena kontrole		srednje
Raspon ruku		slabo
Visina / Težina		skoro nimalo

Podsjeti se na primjer iz Dijela 2

Kod para Jon Jones / Alex Pereira, najupečatljivije razlike su bile baš niz pobjeda (+21) i vrijeme kontrole (+213 sekundi) — dvije stavke koje su, kako sad vidimo, među najuticajnijim za predikciju pobjednika. Fizički podaci poput visine (razlika = 0) tu nisu bili od velike pomoći.

2. Rezultati — "Kako se meč završava?" (teže pitanje)

Ovdje je "besplatna" polazna linija drugačija: **skoro polovina (47.7%)** svih mečeva u test skupu se završi odlukom sudija (Decision) — najčešći ishod. Dakle, da neko UVIJEK nagađa "biće odluka sudija", bez ikakvog razmišljanja, bio bi u pravu 47.7% puta.

48.1%

Logistička regresija

50.2%

Random Forest

44.6%

LightGBM

(Tačnost. Baseline — uvijek nagađati "Decision" — je 47.7%.)

Na prvi pogled, Random Forest izgleda najbolji (50.2%, jedini iznad baseline-a). Ali kad malo dublje zagrebemo, otkrivamo nešto važno.

Analogija: sinoptičar koji "nikad ne griješi"

Zamisli sinoptičara u gradu gdje je 9 od 10 dana sunčano. On UVIJEK najavljuje "sunčano", bez obzira na stvarno stanje. Tehnički, u pravu je 90% dana — impresivan procenat! Ali potpuno je beskoristan onog dana kad stvarno pada kiša, jer je nikad ne najavi. Visok "procenat tačnosti" ovdje sakriva da alat uopšte ne radi svoj posao.

⚠ Ključan nalaz: Random Forest gotovo nikad ne prepozna "predaju"

Kad smo provjerili, od svih mečeva koji su se u stvarnosti završili predajom (Submission), evo koliko ih je svaki model prepoznao:

Model	Prepoznao KO/TKO	Prepoznao Submission	Prepoznao Odluku
Logistička regresija	44.8%	21.3%	61.8%
Random Forest	30.6%	5.4%	82.5%
LightGBM	42.3%	34.1%	50.6%

Random Forest je gotovo naš "sinoptičar" iz primjera gore: skoro uvijek "nagađa" Decision (82.5% takvih slučajeva prepozna) — što mu diže ukupnu tačnost — ali zauzvrat, od svakih 100 pravih pobjeda predajom, prepozna samo **5 ili 6**.

. Za nekog ko traži predikciju "hoće li ovo biti predaja", Random Forest je gotovo beskoristan, uprkos najvišoj "sirovoj" tačnosti.

✓ Preporuka

Za pitanje "kako se meč završava", Logistička regresija i LightGBM su smisleniji izbor — obje prepoznaju sve tri opcije razumno dobro, iako im je ukupna tačnost niža od Random Forest-a.

Viši procenat nije uvijek bolji model.


Šta najviše utiče na to kako se meč završava

Prosjek pogođenih udaraca




najjače

Sklonost obaranju protivnika




srednje

Vrijeme kontrole




srednje

Pokušaji predaje



slabo

Visina, težina, broj pobjeda/poraza, niz pobjeda...



0 — nimalo

Zanimljiv nalaz

Fizički podaci i cjelokupan skor karijere (koliko je borac visok/težak, koliko ima pobjeda/poraza)

uopšte ne govore ništa

o tome KAKO će se meč završiti — logično, jer tvoj rekord ne otkriva tvoj *stil* borbe. Samo bihevioralni podaci (koliko udara, koliko pokušava obaranja/predaje) nose taj signal. Ovo potvrđuje da su naši podaci i pristup smisleni — model je sam "otkrio" ovu logičnu razliku.

3. Zašto je "kako se završava" teže pitanje

"Ko pobjeđuje" zavisi uglavnom od toga ko je **opštenito bolji borac** — to je relativno stabilan, predvidljiv obrazac kroz karijeru. "Kako će se ta pobjeda konkretno dogoditi" zavisi od mnogo specifičnijih stvari te konkretne večeri — trenutak greške, sudijska procjena u odluci, "hemija" između dva konkretna stila — stvari koje prosječne karijerne statistike jednostavno ne mogu uhvatiti unaprijed. Ovo nije samo ograničenje našeg sistema — čak i najveći UFC eksperti mnogo lakše pogode pobjednika nego tačan način završetka.

4. Šta ovo znači za tebe kao korisnika aplikacije

Pitanje	Preporuka
Ko pobjeđuje?	Rezultatu možeš vjerovati razumno — bolji je od nagađanja za oko 10-13 procentnih poena, iako nikad neće biti savršen (sport je nepredvidiv)
Kako se meč završava?	Uzmi kao grubu naznaku, ne sigurnu stvar. Preporučujemo LightGBM ili Logističku regresiju — ne oslanjaj se samo na Random Forest za ovo pitanje
Opšti savjet	Isprobaj sva tri modela za isti meč. Ako se slažu, to je dobar znak; ako se razilaze, meč je "teško čitljiv" čak i za sistem

5. Iskrena ograničenja (sažetak iz svih dijelova)

Ograničenje	Objašnjenje
Nekoliko imena boraca se preklapa	7 imena u podacima pripada dvjema različitim stvarnim osobama (Dio 1) — rijetka, ali postojeća nesavršenost u izvornim podacima
Manje kategorije su manje pouzdane	Npr. Women's Featherweight ima svega 30 mečeva u historiji — manje "primjera za učenje" znači manje pouzdanu procjenu tamo
Nema "međusobni skor"	Model ne zna ko je koga već pobijedio u prošlosti (Dio 2) — moguće buduće poboljšanje
Testirano na nasumičnim starim mečevima	Nismo posebno testirali "da li bismo tačno predvidjeli sljedeću sezonu unaprijed" — samo nasumično odabrane mečeve iz cijele historije

6. Zaključak cijelog serijala

Dio	Šta smo pokrili
1 — Podaci	4455 boraca, 8377 očišćenih mečeva; popravili nedostajuće podatke; izbacili nejasne ishode
2 — Kako računar uči	Gradimo "dosje forme" iz ranijih mečeva; gledamo razlike, ne apsolutne brojke; dupliramo mečeve za fer igru
3 — Modeli	Tri različita pristupa: formula bodovanja, vijeće mini-sudija, tim koji uči na greškama
4 — Rezultati (ovaj dokument)	Ko pobjeđuje: solidno (60-63%). Kako se završava: mnogo teže (44-50%), i model sa najvišim procentom nije uvijek najkorisniji

Glavna poruka cijelog projekta

Model koji na papiru ima najveći procenat tačnosti

nije automatski i najbolji izbor

— treba pogledati dublje, i provjeriti da li taj model radi svoj posao pošteno za SVE moguće ishode, ne samo za najčešći. Ista lekcija vrijedi i šire od UFC predikcija — kad god neko hvali "X% tačnosti", vrijedi zapitati se: tačnost za *šta tačno*, i da li ta brojka sakriva nešto važno.