

Šta se dešava kad kliknem "Predict"?

Korak po korak, sa stvarnim brojevima iz aplikacije: kako se dva izabrana borca pretvaraju u vektor podataka, kako se taj vektor množi s naučenim težinama, i kako se dobija konačna vjerovatnoća — za oba modela koja aplikacija istovremeno prikazuje (pobjednik i način završetka).

Conor McGregor

VS

Khabib Nurmagomedov



Kategorija: Lightweight (155 lbs) · Title fight: da · Model prikazan u ovom dokumentu: **Logistic Regression**
Generisano iz stvarno pokrenute aplikacije (backend API, live inference) · Septembar 2026

0. Zašto baš Logistic Regression za ovaj prikaz

Aplikacija nudi tri modela: **Logistic Regression**, **Random Forest** i **LightGBM**. Sva tri rade identičan prvi korak (isti ulazni vektor, ista standardizacija) — razlikuju se samo u tome *kako* taj vektor pretvaraju u vjerovatnoću:

Logistic Regression — eksplicitne težine Svaki feature ima *jedan broj* (težinu) koji se direktno množi s vrijednošću featurea. Cijeli izračun stane u jednu tabelu — zato je idealan za ovaj vodič: možemo pokazati *tačno* koliko je koji podatak doprinio rezultatu.

Random Forest / LightGBM — stabla odluke Ne postoji jedna "težina" po featureu — umjesto toga, stotine malih stabala odlučuju preko niza pragova (npr. "da li je `win_streak_diff < -5`?"), pa glasaju/usrednjavaju. Nema jedinstvene formule koja stane na papir, pa ih ovaj dokument ne razlaže korak-po-korak — koncept toka podataka (1-3 na prethodnoj strani) je identičan.

Svi brojevi u ovom dokumentu su **stvarno izračunati** pozivanjem pokrenutog backend API-ja i direktnim čitanjem naučenih parametara iz `models/winner_logistic_regression.joblib` i `models/method_logistic_regression.joblib` — ništa nije ilustrativno/izmišljeno.

Bitna metodološka napomena

Ovo NIJE pokušaj da se rekonstruiše stvarni ishod meča iz oktobra 2018. na osnovu tadašnjeg znanja. Aplikacija svaki upit računa "point-in-time" u odnosu na **trenutak upita (danas)**, koristeći KOMPLETNU istoriju oba borca koja postoji u datasetu — uključujući i mečeve odigrane nakon stvarnog UFC 229 (npr. McGregorove mečeve protiv Poiriera i Chandlera, ili Khabibove protiv Poiriera i Gaethjea). Ovo je hipotetički upit: "da se ova dva borca danas suoče, sa kompletnom karijerom kakvu danas poznajemo."

1. Ulazni podaci — dva borca

Korisnik u aplikaciji bira dva borca iz baze od 4455 boraca i kategoriju. Ispod su podaci koje sistem zna o svakom — **career statistike** (trenutni, kumulativni presjek iz `ufc_fighters_final.csv`, prikazuju se samo u UI-ju) i **point-in-time statistike** (rekonstruisane iz istorije mečeva, i to su jedine koje ulaze u model).

FIGHTER A · CRVENI UGAO		FIGHTER B · PLAVI UGAO	
Conor McGregor		Khabib Nurmagomedov	
22–6–0 (career) · Southpaw · 38.2 god.		29–0–0 (career) · Orthodox · 38.0 god.	
Visina / Raspon ruku	175 cm / 188 cm (74")	Visina / Raspon ruku	178 cm / 178 cm (70")
Težina	155 lbs	Težina	155 lbs
SLpM / Str. tačnost	5.32 / 49%	SLpM / Str. tačnost	4.10 / 48%
SAPM / Str. odbrana	4.66 / 54%	SAPM / Str. odbrana	1.75 / 65%
TD prosjek / tačnost	0.67 / 55%	TD prosjek / tačnost	5.32 / 48%
Sub. pokušaji / meč	0.10	Sub. pokušaji / meč	0.80
Point-in-time (u modelu):		Point-in-time (u modelu):	
Prijašnjih mečeva	14	Prijašnjih mečeva	13
Pobjede / porazi	10 / 4	Pobjede / porazi	13 / 0
Trenutni niz pobjeda	0	Trenutni niz pobjeda	13
Dana od zadnjeg meča	1887	Dana od zadnjeg meča	2146
Prosj. sig. udarci (landed/att)	42.8 / 86.0	Prosj. sig. udarci (landed/att)	54.2 / 111.1
Prosj. takedowni (landed/att)	0.36 / 0.64	Prosj. takedowni (landed/att)	4.69 / 9.77
Prosj. kontrola / KD	59.4s / 0.93	Prosj. kontrola / KD	437.0s / 0.15

Zašto se career i point-in-time brojevi razlikuju

Career kolone (22–6 za McGregora) dolaze direktno iz `ufc_fighters_final.csv` i uključuju sve zabilježene mečeve. Point-in-time brojevi (10–4, 14 mečeva) rekonstruisani su isključivo iz mečeva koji postoje u `ufc_gold_dataset_final.csv` — samo iz njih model uopšte može izvući per-fight statistiku (udarci, takedowni, kontrola po meču), pa se koriste dosljedno svuda kao ulaz u model.

2. Građenje ulaznog vektora: razlika (A – B)

Model nikad ne vidi "McGregorove" i "Khabibove" brojeve odvojeno — vidi samo **razliku** A–B za svaki numerički feature. Ovo je namjerna arhitekturna odluka: ista razlika (npr. "borac A ima 13 mečeva manje niz pobjeda od B") znači isto bez obzira ko je fizički naveden kao "borac 1" u aplikaciji.

Feature	Conor (A)	Khabib (B)	Razlika (A–B)
height_in — visina (inch)	69.0	70.0	–1.0
reach_in — raspon ruku (inch)	74.0	70.0	+4.0
weight_lbs — težina	155.0	155.0	0.0
age_years — starost (danas)	38.15	37.97	+0.19
prior_fight_count — broj prijašnjih mečeva	14	13	+1
prior_wins — prijašnje pobjede	10	13	–3
prior_losses — prijašnji porazi	4	0	+4
win_streak — trenutni niz pobjeda	0	13	–13
days_since_last_fight	1887	2146	–259
prior_avg_sig_landed — prosj. pogođeni udarci	42.79	54.23	–11.45
prior_avg_sig_att — prosj. pokušani udarci	86.00	111.08	–25.08
prior_avg_td_landed — prosj. uspješni takedowni	0.357	4.692	–4.34
prior_avg_td_att — prosj. pokušaji takedowna	0.643	9.769	–9.13
prior_avg_sub_att — prosj. pokušaji submissiona	0.071	0.692	–0.62
prior_avg_ctrl_sec — prosj. kontrola (sek)	59.4	437.0	–377.6
prior_avg_kd — prosj. knockdowni	0.929	0.154	+0.77

+ Kategorijski i binarni featurei (dodati bez razlike, svaki kao 0/1 kolona)

Feature	Vrijednost za ovaj meč
stance_a	Southpaw → kolona stance_a_Southpaw = 1, sve ostale stance_a* kolone = 0
stance_b	Orthodox → kolona stance_b_Orthodox = 1
weight_class	Lightweight → kolona weight_class_Lightweight = 1
is_title_fight	1 (title fight uključen)
reach_missing_a/b, height_missing_a/b, weight_missing_a/b, is_debut_a/b	svi 0 — oba borca imaju kompletne podatke i nijedan nije debitant

Konačan vektor ima **51 kolonu** (16 numeričkih razlika + 34 one-hot/flag kolone) — identičan raspored kolona koji su modeli vidjeli tokom treniranja, spašen u `models/feature_columns.json`, da bi svaki live upit bio poravnat sa onim na čemu je model treniran.

Nema curenja podataka (data leakage)

Ni jedna od ovih vrijednosti nije izmjerena TOKOM meča koji se predviđa — sve dolaze iz mečeva koji su se već desili PRIJE trenutka upita. Kolone poput "sig. udarci pogođeni" računaju se kao prosjek isključivo iz ranijih mečeva (cumsum-minus-current trik), nikad iz meča koji je predmet predikcije.

3. Standardizacija i Winner model — računanje

Prije nego što uđu u model, sve numeričke vrijednosti se **standardizuju** (z-score) — svaka se transformiše u "koliko standardnih devijacija je udaljena od prosjeka", koristeći prosjek i devijaciju izračunate na svih 16754 redova trening skupa. Ovo sprječava da featurei s prirodno velikim brojevima (npr. kontrola u sekundama, do ±380) dominiraju nad onima s malim rasponom (npr. razlika u godinama, ±0.2) samo zbog skale.

STANDARDIZACIJA


$$z = (x - \mu) / \sigma$$

LOGISTIC REGRESSION — WINNER MODEL

$$\text{logit} = \sum(\text{težina}_i \times z_i) + \text{intercept} \quad P(\text{A pobjeđuje}) = 1 / (1 + e^{-\text{logit}})$$

Svaki feature (nakon standardizacije) množi se sa svojom naučenom težinom — to je "koliko taj podatak utiče na predikciju, i u kom smjeru". Doprinosi se zbroje, doda se intercept (kod winner modela ≈ 0), i rezultat (logit) se protisne kroz sigmoid funkciju koja ga pretvori u vjerovatnoću 0–1.

Doprinos svakog featurea logitu (crveno = ide u prilog McGregoru, plavo = ide u prilog Khabibu)




Zašto je prior_avg_ctrl_sec_diff "pozitivan" iako Khabib kontroliše duže

Predznak pojedinačne težine se ne smije čitati izolovano/uzročno — featurei su međusobno korelisani (kontrola je usko povezana s uspješnim takedownima, koji već imaju svoj, jači, negativni doprinos). Model raspoređuje "kredit" između korelisanih featurea na način koji ponekad djeluje kontraintuitivno feature-po-feature, iako je ukupan zbir ispravan i dobro kalibrisan.

Zbrajanje i konačna vjerovatnoća

Zbir svih doprinosa ($\sum \text{težina} \times z$)	-1.3989
+ intercept	≈ 0.0000
= logit	-1.3989



79.7%

Khabib Nurmagomedov pobjeđuje

20.3%


Conor McGregor pobjeđuje

4. Method model — računanje (3 paralelna izračuna)

Method model rješava drugačiji problem — 3 klase (KO/TKO, Submission, Decision) umjesto 2. Zato Logistic Regression ovdje interno drži **tri odvojena seta težina**, po jedan za svaku klasu, i svaki set nezavisno računa svoj logit iz *istog standardizovanog vektora* koji smo vidjeli na prošloj strani.

SOFTMAX — PRETVARA 3 LOGITA U 3 VJEROVATNOĆE KOJE SEBERU NA 100%

$$P(\text{klasa } c) = e^{\text{logit}_c} / \sum_{c'} e^{\text{logit}_{c'}}$$



Koji featurei zapravo grade ova tri logita?

Feature	z-score	w (Decision)	w (KO/TKO)	w (Submission)
is_title_fight	4.131	-0.0414	+0.0242	+0.0172
weight_class_Lightweight	2.190	-0.0050	-0.0297	+0.0347
stance_a_Southpaw	2.034	+0.0101	-0.0079	-0.0022
stance_b_Orthodox	0.590	+0.0118	-0.0085	-0.0033
prior_avg_sig_landed_diff (i svih 14 preostalih numeričkih diff-ova)	-0.415	≈ 0.00000000000006	≈ -0.00000000000001	≈ -0.00000000000005

Svih 15–16 numeričkih "diff" featurea (starost, forma, udarci, takedowni, kontrola...) imaju težinu praktično jednaku nuli za sve tri klase Method modela — vidi zašto na sljedećoj strani.

5. Ključni nalaz: zašto Method model "ignoriše" statistiku borbe

Ovo nije greška ni slučajnost — direktna je matematička posljedica jedne odluke iz treniranja, verifikovana direktno na trening podacima (16754 redova).

Augmentacija zamjenom strana (spomenuta u odjeljku 5 PROJECT_CONTEXT.md)

Svaki meč ulazi u trening skup DVA puta: jednom kao (A–B, label) i jednom kao (B–A, label) — da bi Winner model naučio da redoslijed borac1/borac2 ne smije uticati na predikciju. Efekat te iste augmentacije na Method model je suptilan: `method_class` (KO/TKO, Submission, Decision) se **ne mijenja** kad se strane zamjene — isti meč, isti ishod-po-metodi, bez obzira ko je "A". Ali svaka numerička `_diff` kolona mijenja predznak (+11 postaje –11).

Rezultat: za svaki numerički feature i svaku klasu metode, prosjek te kolone po klasi je **tačno nula** (izmjereno direktno na podacima, ne teorijski):

method_class	prosijek prior_avg_sig_landed_diff	broj redova
Decision	0.00000000000000000036	7874
KO_TKO	0.00000000000000000077	5570
Submission	0.00000000000000000000	3310

Kad su prosjeci po klasama identični (svi ≈ 0), jednosmjerna ANOVA (koja mjeri koliko se prosjeci RAZLIKUJU između klasa) ne nalazi baš nikakav signal — F-statistika izlazi $\approx 0.0000000000000000000000000008$, sa p-vrijednošću tačno 1.0 (potpuno beznačajno). Logistic Regression (linearan model) matematički **mora** konvergirati ka težini ≈ 0 za takve featurese, jer bilo koja druga težina bi kažnjavala model na jednom od dva "ogledalna" reda istog meča.

Posljedica za UI aplikacije

Panel "top featurei" koji app prikazuje za Method model (ANOVA feature importance, globalno — nezavisno od konkretnog para boraca) trenutno na vrhu liste ističe baš `prior_avg_sig_landed_diff` (score 100/100). Prema gornjoj analizi, taj broj je zapravo numerički šum između featurea koji su SVI podjednako (potpuno) nesignifikantni za ovaj target — ne stvarna najvažnija varijabla. Stvarni, upotrebljivi signal za Method kod Logistic Regression dolazi od featurea koji **NE** mijenjaju predznak pri zamjeni strana: `is_title_fight`, `weight_class_*`, i `stance` kolone.

Potvrda brojkama: prosječna |težina| po grupi featurea i modelu

	Winner model		Method model
Numerički diff-ovi	0.1467	Numerički diff-ovi	0.000000000000
Kategorijski/flag	0.0445	Kategorijski/flag	0.0353

Kod Winner modela numerički featurei nose gotovo 3× veću prosječnu težinu od kategorijskih. Kod Method modela je obrnuto — numerički featurei su praktično na nuli, kategorijski/flag featurei nose (skoro) sav stvarni signal.

Nelinearni modeli (Random Forest, LightGBM) ovom problemu nisu podložni

Stablo odluke može direktno pitati "da li je `|prior_avg_sig_landed_diff|` veliko?" kroz kombinaciju dva prara (jedan za pozitivne, jedan za negativne vrijednosti), pa augmentacija zamjenom strana ne prisiljava njihove numeričke featurese ka nuli na isti način. Ovo je vjerovatno i razlog zašto je u ranijoj evaluaciji Random Forest imao najvišu accuracy za Method cilj (50.2%) uprkos nižem macro-F1.

6. Sažetak i ograničenja

Konačan rezultat za ovaj upit (Logistic Regression)

79.7%

Khabib pobjeđuje

29.7%

... Decision-om

32.8%

... KO / TKO-om

37.4%

... Submissionom

Method predikcija ne kaže KO pobjeđuje na taj način

Kao što je već ranije razjašnjeno u razgovoru: "37.4% Submission" je vjerovatnoća da se MEČ generalno završi submissionom — ne "37.4% da Khabib pobijedi submissionom". Winner i Method model su statistički nezavisni; Method model ne zna šta je Winner model predvidio, niti čak ko je "pobjednik" u ovom konkretnom upitu.

Ostala ograničenja ovog prikaza

- Prikazan je isključivo **Logistic Regression** put; Random Forest i LightGBM prolaze kroz iste korake 1–3 (feature vektor, standardizacija za RF nije ni potrebna jer stabla ne zavise od skale featura, ali pipeline je ostao konzistentan), a zatim kroz stotine stabala umjesto eksplicitnih težina.
- Metrike modela prikazane u aplikaciji (accuracy, log-loss, cross-validation) odnose se na CIJELI test skup (3352 mečeva), ne na ovaj konkretan par boraca — ne postoji garancija da je baš OVA predikcija tačna.
- Age_years se računa u odnosu na DANAŠNJI datum (2026), ne na datum stvarnog meča iz 2018 — vidi napomenu u odjeljku 0.
- 7 imena boraca u datasetu (0.3%) su duplikati različitih osoba; McGregor i Khabib nisu među njima (podatak provjeren u analizi projekta).

UFC Fight Predictor · svi brojevi u ovom dokumentu izvučeni su direktno iz pokrenute aplikacije (backend API na 127.0.0.1:8000) i naučenih model artefakata (models/*.joblib), septembar 2026.