

# UFC Predictor — rezultati modela

2026-09-16 · @Someone

Dva cilja predikcije (pobjednik, način pobjede), tri algoritma (Logistic Regression, Random Forest, LightGBM), trenirana na 13.402 UFC mečeva kroz dva različita načina pripreme i serviranja ulaznih podataka modelu — diff i concat reprezentaciju. Najvažniji nalazi: sirova accuracy zavarava (Random Forest gotovo potpuno ignoriše Submission ishod uz svega 5,4% recall, uprkos najvišoj tačnosti), a diff reprezentacija već hvata gotovo sav koristan signal koji concat pokušava dodatno ponuditi.

## Skup podataka i cilj

Modeli su trenirani na historijskim UFC mečevima: 13.402 redova za trening, 3.352 za test (grupisano po meču, tako da obje simetrične verzije istog meča ostanu na istoj strani splita). Dva odvojena cilja predikcije:

- **Winner** — binarna klasifikacija (koji borac pobjeđuje)
- **Method** — 3-klasna klasifikacija (KO/TKO, Submission, Decision)

Ulazne karakteristike (15 numeričkih + kategorijske) računaju se *point-in-time* — samo iz podataka dostupnih prije datog meča (career prosjeci, streak, fizički atributi), čime se izbjegava curenje podataka iz budućnosti.

## Priprema podataka

### Izvorni podaci

Za potrebe ovog rada dobivena su dva sirova skupa podataka u CSV formatu, preuzeta sa [ufcstats.com](https://ufcstats.com). Prvi, `ufc_fighters_final.csv`, sadrži presjek trenutnog stanja karijere svakog borca (4455 redova, 18 kolona) — fizički atributi (visina, domet, težina, stav), datum rođenja i agregatni career pokazatelji. Drugi, `ufc_gold_dataset_final.csv`, sadrži ishod i statistiku svakog pojedinačnog meča (8551 redova, 37 kolona) — pobjednik, način završetka i granularne borbene statistike po borcu (značajni udarci, obaranja, vrijeme kontrole, pokušaji submissiona, nokdauni). Podaci obuhvataju cijelu zabilježenu istoriju organizacije, od 11.3.1994. do 7.3.2026. godine.

### Šta je nedostajalo

Analizom kompletnosti podataka uočeno je više nedostajućih vrijednosti kod atributa boraca: domet (Reach) nedostaje kod 43,6% boraca, stav (Stance) kod 19,1%, visina kod 7,1%, a težina kod 1,9%. Pored toga, 123 različite sirove tekstualne vrijednosti kategorije

težinske klase (npr. „UFC Lightweight Title Bout“, „Catch Weight Bout“) trebalo je svesti na jedinstvenu šemu. Uočen je i problem koji nije bilo moguće u potpunosti riješiti: sedam imena boraca (koja odgovaraju za 14 različitih stvarnih osoba, npr. dva različita borca imenom „Bruno Silva“) pojavljuju se dvaput u skupu podataka o borcima, dok skup podataka o mečevima borce referencira isključivo po imenu, bez jedinstvenog identifikatora. Ovaj nedostatak je zadržan kao dokumentovano ograničenje rada, s obzirom da uklanjanje pogodenih redova ne bi bilo opravdano u odnosu na veličinu problema (svega 0,3% redova).

## Šta smo mogli iskoristiti, a šta smo odbacili

Od ukupno 8551 zabilježena meča, 174 (~2,0%) nije imalo jasno definisan ishod — 151 meč je završilo neriješeno ili bez odluke (Draw/NC), 58 je poništeno (Overturned), 32 nije moglo biti nastavljeno, 23 su završena diskvalifikacijom, a 2 su označena kao „Other“. Ovi redovi ne nose čist signal o tome ko je objektivno bolji borac niti kako se meč prirodno završio, pa su u potpunosti izbačeni iz daljnje obrade.

Granularne borbene statistike iz `ufc_gold_dataset_final.csv` (npr. broj sletjelih udaraca ili obaranja u konkretnom meču) predstavljaju **rezultat** tog istog meča, pa se nisu mogle direktno iskoristiti kao ulazni podatak za predviđanje ishoda tog istog meča — to bi značilo da model „vidi“ ono što pokušava predvidjeti (tzv. curenje podataka, data leakage). Umjesto direktnog korištenja, ovi podaci su iskorišteni posredno, kao osnova za izračun istorijskih (career) prosjeka svakog borca prije datog meča, što je detaljnije opisano u nastavku.

## Deskriptivna statistika

Nakon čišćenja, očišćeni skup od 8377 mečeva raspoređen je po načinu završetka i težinskoj kategoriji na sljedeći način.

| Način završetka | Broj mečeva | Udio  |
|-----------------|-------------|-------|
| Decision        | 3937        | 47,0% |
| KO_TKO          | 2785        | 33,2% |
| Submission      | 1655        | 19,8% |

Ova raspodjela direktno objašnjava zbog čega je baseline (uvijek predviđati Decision) za Method cilj 47,7% — Decision je ubjedljivo najzastupljenija klasa, a Submission je gotovo dvostruko rjeđi od KO\_TKO.

| Težinska kategorija   | Broj mečeva |
|-----------------------|-------------|
| Lightweight           | 1403        |
| Welterweight          | 1360        |
| Middleweight          | 1108        |
| Featherweight         | 826         |
| Bantamweight          | 747         |
| Heavyweight           | 741         |
| Light Heavyweight     | 725         |
| Flyweight             | 403         |
| Women's Strawweight   | 355         |
| Women's Flyweight     | 265         |
| Women's Bantamweight  | 237         |
| Open Weight           | 86          |
| Catch Weight          | 78          |
| Women's Featherweight | 30          |
| Unknown               | 13          |

Raspodjela je izrazito neravnomjerna — tri najveće kategorije (Lightweight, Welterweight, Middleweight) čine preko 40% svih mečeva, dok najmanje kategorije (Women's Featherweight, Unknown) imaju svega 13–30 mečeva, što širi interval povjerenja za predikcije u tim kategorijama.

Među numeričkim obilježjima izračunata je Pearsonova korelacija; najjači parovi ( $|r| > 0,6$ ) prikazani su ispod.

| Par obilježja                                         | r     |
|-------------------------------------------------------|-------|
| prior_fight_count_diff ↔ prior_wins_diff              | 0,958 |
| prior_avg_sig_landed_diff ↔<br>prior_avg_sig_att_diff | 0,939 |
| prior_fight_count_diff ↔ prior_losses_diff            | 0,913 |

| Par obilježja                                      | r     |
|----------------------------------------------------|-------|
| prior_avg_td_landed_diff ↔ prior_avg_td_att_diff   | 0,830 |
| prior_avg_td_landed_diff ↔ prior_avg_ctrl_sec_diff | 0,768 |
| prior_wins_diff ↔ prior_losses_diff                | 0,757 |
| prior_avg_td_att_diff ↔ prior_avg_ctrl_sec_diff    | 0,702 |
| height_in_diff ↔ reach_in_diff                     | 0,659 |

Ovi parovi su očekivani (duplja karijera prirodno donosi i više pobjeda i više poraza; ko pokušava više obaranja, taj ih i više uspješno izvede) i predstavljaju upravo onu multikolinearnost na koju se referira odjeljak „Šta je uticalo na dobijenu tačnost“ — modeli bazirani na stablima su na nju relativno otporni, dok Logistic Regression može biti nešto osjetljiviji.

## Šta smo naknadno računali

Na temelju očišćenih sirovih podataka izvedeno je više novih obilježja, koja u izvornim fajlovima nisu postojala:

- 1. Istorijski (point-in-time) prosjeci forme borca** — za svaki meč i svakog borca izračunat je broj ranijih mečeva, pobjeda, poraza, trenutni niz pobjeda (win streak), broj dana od posljednjeg meča, te prosječan broj značajnih udaraca, obaranja, pokušaja submissiona, vremena kontrole i nokdauna — računato isključivo iz mečeva odigranih **strogo prije** datuma meča koji se predviđa. Za borca na debiju (bez ranijih mečeva), ovi prosjeci postavljeni su na 0 uz poseban indikator `is_debut`.
- 2. Imputirane vrijednosti** za nedostajuće fizičke attribute: domet je procijenjen linearnom regresijom u odnosu na visinu ( $\text{reach} = 1,0524 \times \text{height} - 1,9828$ ), dok su visina i težina procijenjene medijanom unutar borčeve težinske kategorije. Svaka procijenjena vrijednost prati poseban `*_missing` indikator, kako bi model razlikovao stvarno izmjerenu od procijenjene vrijednosti.
- 3. Normalizovana kategorija težinske klase** — 123 različite sirove vrijednosti svedene su na 15 kanonskih kategorija, uz izdvojen `is_title_fight` indikator za titularne mečeve.
- 4. Normalizovan način završetka meča** — sirove vrijednosti ishoda svedene su na tri klase: KO\_TKO, Submission i Decision.

5. **Razlike (ili odvojene vrijednosti) između dvojice boraca** po svakom numeričkom obilježju — način na koji su izračunate detaljnije je opisan u narednom odjeljku, jer se ovdje javljaju dvije različite varijante pripreme podataka za trening.

## Koji podaci ulaze u trening i na koji način

Svaki meč u finalnoj tabeli za trening zapisan je kao jedan red koji kombinuje obilježja oba borca. Kako bi model bio neosjetljiv na to koji je borac naveden prvi u izvornom zapisu (što nema stvarno značenje), svaki meč je dodatno dupliciran sa zamijenjenim stranama i invertovanim brojnim vrijednostima, dok se oznaka načina završetka ne mijenja jer ne zavisi od redoslijeda boraca. Ovim postupkom se od 8377 očišćenih mečeva dobija konačna tabela od 16754 redova. Podaci su potom podijeljeni na skup za trening (13402 reda, 80%) i skup za testiranje (3352 reda, 20%), pri čemu je podjela grupisana po meču kako obje simetrične verzije istog meča ne bi završile na različitim stranama podjele. Ista logika izgradnje obilježja korištena je i za treniranje modela i za generisanje ulaznog vektora prilikom stvarne (žive) predikcije, čime je izbjegnuta neusklađenost između produkcije i treninga.

## Dvije reprezentacije trening podataka

U okviru rada isprobane su dvije različite reprezentacije istih ulaznih podataka, kako bismo ispitali utječe li način zapisa informacije o dvojici boraca na uspješnost modela:

| Reprezentacija                                        | Način zapisa                                                                                                                                        | Broj numeričkih kolona |
|-------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------|------------------------|
| <b>diff</b> (podrazumijevana, korištena u produkciji) | Za svako obilježje računa se razlika vrijednosti borca A i borca B (npr. <code>age_years_diff = age_a - age_b</code> )                              | 16                     |
| <b>concat</b> (eksperimentalna)                       | Vrijednosti oba borca zadržane su kao odvojene kolone (npr. <code>age_years_a</code> , <code>age_years_b</code> ), bez unaprijed izračunate razlike | 32                     |

Razlika između ove dvije varijante svodi se isključivo na posljednji korak pripreme podataka — obje polaze od potpuno istih sirovih i historijskih obilježja. Kod **diff** varijante, model odmah dobija već izračunatu razliku između boraca, čime mu je poređenje unašeno u podatke. Kod **concat** varijante, model dobija obje vrijednosti odvojeno i sam mora naučiti da ih uporedi, što teoretski omogućava složenije, asimetrične obrasce poređenja (npr. da razlika u starosti ima drugačiji značaj kod jednog stila borbe nego kod drugog). Objе varijante koriste identičan skup od 16754 redova; concat varijanta, nakon uključivanja

kategorijskih obilježja, rezultira sa 68 finalnih kolona naspram 52 kod diff varijante. Konkretni rezultati poređenja ove dvije reprezentacije po modelu i cilju predikcije prikazani su u odjeljku „Eksperiment: diff vs. concat reprezentacija featura“.

### Priprema podataka za diff trening (produkcijaska varijanta)

1. Polazište je identična istorijska tabela od 16754 redova (jedan red po meču po strani, nakon simetrične augmentacije opisane ranije).
2. Za svako od 16 numeričkih obilježja (statika + istorijski prosjeci) izračunava se razlika `a - b`, čime nastaje 16 `_diff` kolona (npr. `age_years_diff`).
3. Tri kategorijska obilježja (`stance_a`, `stance_b`, `weight_class`) one-hot enkodiraju se u ukupno 27 binarnih kolona (12 za stav svakog borca + 15 za težinsku kategoriju).
4. Dodaje se 9 binarnih zastavica (title fight, indikatori nedostajućih/procijenjenih vrijednosti, indikatori debija).
5. Rezultat: **52 finalne kolone**. Ovo je podrazumijevana, produkcijska varijanta — jedina koju koristi automatizovani admin retrain tok, i jedina koju Logistic Regression dodatno skalira (`StandardScaler`) unutar pipeline-a prije treninga.

### Priprema podataka za concat trening (eksperimentalna varijanta)

1. Polazište je **potpuno ista** istorijska tabela od 16754 redova — concat varijanta ne uvodi nijedan novi podatak, samo drugačiji zapis istih brojeva.
2. Za svako od istih 16 numeričkih obilježja **ne** računa se razlika — umjesto toga zadržavaju se obje vrijednosti odvojeno, što daje 32 kolone (16 s nastavkom `_a` + 16 s nastavkom `_b`, npr. `age_years_a`, `age_years_b`).
3. Kategorijska obilježja i zastavice pripremaju se na identičan način kao kod diff varijante (27 + 9 = 36 kolona), bez izmjena.
4. Rezultat: **68 finalnih kolona**. Ova varijanta generiše se ručno (`python -m app.ml.features concat && python -m app.ml.train concat`), čuva se u zasebnom folderu (`backend/models/variants/concat/`) i nije uključena u automatizovani retrain tok, upravo kako bi ostala izolovana od produkcijskog sistema tokom eksperimentisanja.

### Popis svih varijabli

U nastavku je naveden kompletan popis od 52 kolone diff varijante, bez izuzetka. Kod concat varijante, 16 numeričkih obilježja iz prve tabele ne dolazi kao `_diff`, nego u dva primjerka sa nastavcima `_a` i `_b` (npr. `age_years_a`, `age_years_b`) — preostalih 36 kolona (kategorije i zastavice) identično je u obje varijante.

#### 1. Numerička obilježja (16) — kod diff varijante kao razlika `a - b`

| Kolona (diff)              | Opis                                                 |
|----------------------------|------------------------------------------------------|
| height_in_diff             | Razlika visine (inči)                                |
| reach_in_diff              | Razlika dometa (inči)                                |
| weight_lbs_diff            | Razlika težine (funte)                               |
| age_years_diff             | Razlika starosti (godine)                            |
| prior_fight_count_diff     | Razlika broja ranijih mečeva                         |
| prior_wins_diff            | Razlika broja ranijih pobjeda                        |
| prior_losses_diff          | Razlika broja ranijih poraza                         |
| win_streak_diff            | Razlika trenutnog niza pobjeda                       |
| days_since_last_fight_diff | Razlika broja dana od posljednjeg meča               |
| prior_avg_sig_landed_diff  | Razlika prosječnog broja sletjelih značajnih udaraca |
| prior_avg_sig_att_diff     | Razlika prosječnog broja pokušaja značajnih udaraca  |
| prior_avg_td_landed_diff   | Razlika prosječnog broja uspješnih obaranja          |
| prior_avg_td_att_diff      | Razlika prosječnog broja pokušaja obaranja           |
| prior_avg_sub_att_diff     | Razlika prosječnog broja pokušaja submissiona        |
| prior_avg_ctrl_sec_diff    | Razlika prosječnog vremena kontrole (sekunde)        |
| prior_avg_kd_diff          | Razlika prosječnog broja nokdauna                    |

## 2. Binarne zastavice (9)

| Kolona                                                           | Opis                                                    |
|------------------------------------------------------------------|---------------------------------------------------------|
| <code>is_title_fight</code>                                      | Da li je meč za titulu                                  |
| <code>reach_missing_a</code> , <code>reach_missing_b</code>      | Domet borca A/B je procijenjen (imputiran), ne izmjeren |
| <code>height_missing_a</code> ,<br><code>height_missing_b</code> | Visina borca A/B je procijenjena, ne izmjerena          |
| <code>weight_missing_a</code> ,<br><code>weight_missing_b</code> | Težina borca A/B je procijenjena, ne izmjerena          |
| <code>is_debut_a</code> , <code>is_debut_b</code>                | Borac A/B je na svom prvom zabilježenom meču            |

### 3. Kategorijska obilježja (3 izvorne kolone → 27 one-hot kolona)

| Izvorna kolona            | Broj kategorija nakon one-hot enkodiranja | Kategorije                                                                                                                                                                                                                               |
|---------------------------|-------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>stance_a</code>     | 6                                         | Open Stance, Orthodox, Sideways, Southpaw, Switch, Unknown                                                                                                                                                                               |
| <code>stance_b</code>     | 6                                         | Open Stance, Orthodox, Sideways, Southpaw, Switch, Unknown                                                                                                                                                                               |
| <code>weight_class</code> | 15                                        | Bantamweight, Catch Weight, Featherweight, Flyweight, Heavyweight, Light Heavyweight, Lightweight, Middleweight, Open Weight, Unknown, Welterweight, Women's Bantamweight, Women's Featherweight, Women's Flyweight, Women's Strawweight |

Ukupno: 16 (numerička) + 9 (zastavice) + 27 (kategorije) = **52 kolone** za diff varijantu; 32 + 9 + 27 = **68 kolona** za concat varijantu. Ciljna varijabla (label) nije u ovom popisu jer nije ulazna karakteristika — to je `winner` (binarno) ili `method` (KO\_TKO / Submission / Decision), zavisno od cilja predikcije.

### Tok pripreme podataka

Cjelokupan proces pripreme podataka, od sirovih fajlova do konačne tabele spremne za trening, prikazan je na sljedećem dijagramu.

```
flowchart TD
```

```

  A["Sirovi CSV-ovi<br/>fighters + fights"] --> B["Ciscenje i
  filtriranje<br/>izbacivanje mec-eva bez jasnog ishoda"]
  B --> C["Normalizacija<br/>metoda pobjede, tezinska klasa"]
  C --> D["Point-in-time agregacija<br/>istorijski prosjeci po borcu"]
  D --> E["Imputacija<br/>nedostajucih fizickih atributa"]
  E --> F["Spajanje u parove meceva<br/>borac A vs borac B"]
  F --> G{"Format zapisa"}
  G -->|diff| H["Razlika A - B<br/>14 numerickih kolona"]
  G -->|concat| I["A i B odvojeno<br/>28 numerickih kolona"]
  H --> J["Simetricna augmentacija<br/>zamjena strana A/B"]
  I --> J
  J --> K["Trening tabela<br/>16754 redova"]
  K --> L["Trening/test podjela<br/>80/20, grupisano po mecu"]

```

## Modeli i metodologija

Za oba cilja treniraju se ista tri algoritma, birana da pokriju spektar jednostavno/interpretabilno → kompleksno:

| Model               | Tip                               | Ključna karakteristika                                                |
|---------------------|-----------------------------------|-----------------------------------------------------------------------|
| Logistic Regression | linearni baseline                 | direktno interpretabilni koeficijenti, dobro kalibrisane vjerovatnoće |
| Random Forest       | bagging ansambl (300 stabala)     | hvata nelinearne obrasce, ne zahtijeva skaliranje                     |
| LightGBM            | gradient boosting (300 iteracija) | leaf-wise rast, često najbolja kalibracija                            |

Sva tri koriste `class_weight='balanced'` umjesto sintetičkog oversamplinga (SMOTE), da se izbjegne curenje informacija kroz sintetičke primjere.

Evaluacija modela zasniva se na grupisanoj podjeli 80/20 (`GroupShuffleSplit` po meču), koja sprečava da simetrične verzije istog meča završe na različitim stranama podjele, te na petostruko grupisanoj unakrsnoj validaciji. Uspješnost modela mjerena je kroz accuracy, macro-F1 (u kojem je svaka klasa jednako važna, bez obzira na učestalost) te log-loss, koji kanjava loše kalibrisanu vjerovatnoću predviđanja.

## Rezultati — Pobjednik (binarna klasifikacija)

| Model               | Accuracy | Macro-F1 | Log-Loss | CV Accuracy    |
|---------------------|----------|----------|----------|----------------|
| Logistic Regression | 62,71%   | 0,627    | 0,635    | 62,66% ± 1,21% |
| Random Forest       | 61,72%   | 0,617    | 0,643    | 62,35% ± 0,48% |
| LightGBM            | 60,65%   | 0,607    | 0,643    | 61,71% ± 0,89% |

Baseline (nasumican izbor): 50%.

Logistic Regression je najbolji na svim metrikama — odnos između razlike u pred-meč statistikama i pobjednika je pretežno linearan (stariji/iskusniji/u boljoj formi borac pobjeđuje proporcionalno razlici, bez potrebe za složenim nelinearnim interakcijama). Random Forest ima najnižu varijansu kroz foldove ( $\pm 0,48\%$ ) — najstabilniji, iako ne i najtačniji.

## Rezultati — Metoda pobjede (3-klasna)

| Model               | Accuracy | Macro-F1 | Log-Loss | CV Accuracy    |
|---------------------|----------|----------|----------|----------------|
| Logistic Regression | 48,09%   | 0,425    | 1,189    | 43,80% ± 2,45% |
| Random Forest       | 50,21%   | 0,366    | 1,289    | 48,95% ± 1,17% |
| LightGBM            | 44,60%   | 0,421    | 1,263    | 43,84% ± 1,73% |

Baseline (uvijek predviđati najčešću klasu Decision): 47,7%.

Iz navedenih rezultata proizilazi da sama accuracy može biti zavaravajuća mjera uspješnosti: Random Forest ostvaruje najvišu accuracy, tek nešto iznad baseline vrijednosti, ali ima najlošiji macro-F1 i log-loss od sva tri modela. Razlog postaje jasan tek kada se analizira recall po pojedinačnoj klasi.

| Model               | Recall (Submission) | Recall (KO/TKO) | Recall (Decision) |
|---------------------|---------------------|-----------------|-------------------|
| Logistic Regression | 21,3%               | 44,8%           | 61,8%             |
| Random Forest       | 5,4%                | 30,6%           | 82,5%             |
| LightGBM            | 34,1%               | 42,3%           | 50,6%             |

Random Forest praktično uvijek predviđa Decision (82,5% recall tamo) — napuhava accuracy jer je to najčešća klasa, ali model gotovo potpuno ne prepoznaje Submission (samo 37 od 686 tačno pogođenih). Logistic Regression i LightGBM su znatno balansirani kroz sve tri klase, uz nižu ukupnu accuracy — smisleniji izbor za ovaj cilj uprkos nižoj "sirovjoj" tačnosti.

## Najvažniji prediktori (ANOVA F-statistika)

Normalizovano 0–100 (veće = bolje razdvaja klase), računato na trening skupu.

| Feature                                       | Winner | Method |
|-----------------------------------------------|--------|--------|
| age_years_diff (razlika u starosti)           | 100,0  | 13,4   |
| win_streak_diff (trenutni niz pobjeda)        | 66,7   | 0,0    |
| prior_avg_td_landed_diff (obaranja)           | 62,2   | 11,4   |
| prior_avg_sig_landed_diff (volumen udaraca)   | 31,1   | 100,0  |
| prior_avg_sub_att_diff (pokušaji submissiona) | 13,8   | 15,4   |

Za **Winner**, razlika u starosti je ubjedljivo najjači prediktor, prate ga momentum (niz pobjeda) i grappling dominacija. Za **Method**, volumen udaraca najjače razdvaja način završetka.

Ključan nalaz: šest featura (fizički atributi, career-record brojevi) ima **doslovno nultu** ANOVA vrijednost za Method — koliko je borac visok/težak ili koliko ima pobjeda/poraza ne govori ništa o *stil*u kojim će se borba završiti; samo bihevioralni pokazatelji (koliko udara, koliko pokušava obaranja/submissione) nose taj signal.

## Šta je uticalo na dobijenu tačnost

Dobijene vrijednosti tačnosti (60–63% za Winner, 44–50% za Method) nisu proizvoljne — na njih utiče nekoliko međusobno povezanih faktora.

**Veličina i podjela skupa podataka.** Trening skup od 13402 reda dovoljan je za stabilnu procjenu ukupne tačnosti (potvrđeno niskom standardnom devijacijom kroz unakrsnu validaciju, npr.  $\pm 0,48\%$  za Random Forest na Winner cilju), ali test skup rjeđe klase (Submission, 686 redova) čini procjenu recall-a za tu klasu manje stabilnom.

**Inherentna težina problema.** Winner cilj ima jači, dosljedniji signal u podacima jer razlika u iskustvu i formi boraca kroz karijeru relativno pouzdano predviđa ko će pobijediti. Method cilj zavisi od specifične dinamike konkretne borbe (trenutak greške, sudijska procjena)

koja se ne može u potpunosti uhvatiti kroz agregirane career prosjeke — zato baseline i ostvarena tačnost oba padaju kod Method cilja u odnosu na Winner.

**Diskriminativna moć pojedinačnih obilježja (ANOVA).** Za Winner cilj, dominira razlika u starosti ( $F=100$ ) i niz pobjeda ( $F=66,7$ ) — oba fizički smisljena i stabilna kroz karijeru. Za Method cilj, šest obilježja (fizički atributi, career-record brojevi) ima doslovno nultu diskriminativnu moć, što direktno ograničava koliko visoko i jedan model može dosegnuti na tom cilju, bez obzira na algoritam.

**Disbalans klasa i njegovo (ne)rješavanje.** Sva tri modela koriste

`class_weight='balanced'`, ali ovo se pokazalo nedovoljnim za Random Forest na rijetkoj klasi Submission (5,4% recall) — model efektivno nauči da predviđanje najzastupljenije klase (Decision) minimizira ukupnu grešku, što napuhava accuracy bez stvarne korisnosti.

**Induktivna pristrasnost algoritma.** Kod Winner cilja, gdje je odnos ulaza i izlaza pretežno linearan, Logistic Regression prirodno dobija prednost. Kod Method cilja, gdje su granice između klasa manje pravilne, ansambl metode (Random Forest, LightGBM) teoretski imaju prednost u hvatanju nelinearnih obrazaca, ali to ne sprečava Random Forest da se prekomjerno prilagodi većinskoj klasi.

**Multikolinearnost.** Nekoliko parova obilježja jako je korelisano (npr.

`prior_fight_count_diff` i `prior_wins_diff`,  $r=0,958$ ), što djelimično duplira informaciju bez dodavanja novog signala — stabla su na ovo relativno otporna, dok Logistic Regression može biti osjetljiviji.

**Ispravna prevencija curenja podataka.** Budući da su sva istorijska obilježja računata isključivo iz mečeva prije datuma predikcije, dobijene vrijednosti tačnosti predstavljaju realističnu procjenu stvarne prediktivne moći sistema, a ne artefakt curenja podataka koji bi vještački napuhao rezultate.

**Reprezentacija podataka (diff vs. concat).** Kako je pokazano u narednom odjeljku, izbor između diff i concat reprezentacije ima zanemarljiv do mali uticaj na tačnost — dominantni faktori su gore navedeni, ne način zapisa ulaznih podataka.

## Eksperiment: diff vs. concat reprezentacija featura

Pored tri algoritma, testirali smo i da li **način zapisivanja** istih podataka utječe na tačnost — ne novi podaci, samo drugačije upakovani:

- **diff** (podrazumijevano, produkcija): `{feat}_diff = a - b`, npr. `age_years_diff`
- **concat** (eksperimentalno): vrijednosti oba borca kao odvojene kolone (`age_years_a`, `age_years_b`), model sam uči poredbu

**Rezultati — Winner:**

| Model               | diff Accuracy | concat Accuracy | $\Delta$       |
|---------------------|---------------|-----------------|----------------|
| Logistic Regression | 62,71%        | 62,71%          | +0,00pp        |
| Random Forest       | 61,72%        | 61,72%          | +0,00pp        |
| LightGBM            | 60,65%        | 61,61%          | <b>+0,96pp</b> |

## Rezultati — Method:

| Model               | diff Accuracy | concat Accuracy | $\Delta$       |
|---------------------|---------------|-----------------|----------------|
| Logistic Regression | 48,09%        | 43,32%          | <b>-4,77pp</b> |
| Random Forest       | 50,21%        | 51,10%          | +0,89pp        |
| LightGBM            | 44,60%        | 44,63%          | +0,03pp        |

Iz predstavljenih rezultata proizilazi da nijedan model ne ostvaruje jasan i dosljedan dobitak od concat formata u odnosu na oba cilja predikcije, što upućuje na zaključak da diff reprezentacija već obuhvata gotovo sav koristan signal sadržan u podacima. Jedini izuzetak predstavlja Logistic Regression na cilju Method, kod kojeg dolazi do jasnog pogoršanja (-4,77 procentna poena): udvostručavanje broja parametara (sa 16 na 32 kolona) za trirazrednu klasifikaciju sa relativno malim brojem mečeva otvara prostor za overfitting umjesto boljeg modeliranja poređenja. Concat varijanta stoga ostaje eksperimentalna i izolovana od produkcijskog sistema ( `models/variants/concat/` ), te nije uključena u automatizovani proces retreniranja.

## Komparacija algoritama

Tabela ispod sumira sve tri algoritma (Logistic Regression, Random Forest, LightGBM) kroz oba cilja predikcije i sve prateće kriterije, s pobjednikom po svakom kriteriju.

| Kriterij                             | Logistic Regression | Random Forest | LightGBM    | Pobjednik           |
|--------------------------------------|---------------------|---------------|-------------|---------------------|
| Accuracy (Winner)                    | 62,71%              | 61,72%        | 60,65%      | Logistic Regression |
| Macro-F1 (Winner)                    | 0,627               | 0,617         | 0,607       | Logistic Regression |
| Log-Loss (Winner)                    | 0,635               | 0,643         | 0,643       | Logistic Regression |
| CV stabilnost (Winner, $\pm$ st.dev) | $\pm$ 1,21%         | $\pm$ 0,48%   | $\pm$ 0,89% | Random Forest       |

| Kriterij                      | Logistic Regression   | Random Forest | LightGBM | Pobjednik                            |
|-------------------------------|-----------------------|---------------|----------|--------------------------------------|
| Accuracy (Method)             | 48,09%                | 50,21%        | 44,60%   | Random Forest (uz ogradu, vidi niže) |
| Macro-F1 (Method)             | 0,425                 | 0,366         | 0,421    | Logistic Regression                  |
| Log-Loss (Method)             | 1,189                 | 1,289         | 1,263    | Logistic Regression                  |
| Recall na Submission (Method) | 21,3%                 | 5,4%          | 34,1%    | LightGBM                             |
| Interpretabilnost             | Visoka (koeficijenti) | Niska         | Niska    | Logistic Regression                  |
| Robusnost na disbalans klasa  | Dobra                 | Slaba         | Dobra    | Logistic Regression / LightGBM       |

Za **Winner cilj**, Logistic Regression je jasan pobjednik — najbolji na accuracy, macro-F1 i log-loss, uz zanemarivo veću varijansu od Random Forest-a kroz foldove. Ovo se poklapa s analizom u prethodnom odjeljku: kad je odnos ulaza i izlaza pretežno linearan, jednostavniji model ne gubi ništa u odnosu na složenije ansamble.

Za **Method cilj**, slika je složenija i upravo ovdje se accuracy pokazuje kao zavaravajući kriterij: Random Forest ima najvišu accuracy, ali je istovremeno najlošiji na macro-F1, log-loss i recall za manjinsku klasu Submission. Ako je cilj sistema da bude podjednako koristan za sve tri metode završetka, Logistic Regression (najbolja kalibracija i balans) ili LightGBM (najbolji recall na Submission) su smisleniji izbor od Random Forest-a, uprkos njegovoj višoj sirovoj tačnosti.

**Preporuka:** koristiti Logistic Regression kao podrazumijevani model za Winner cilj, a Logistic Regression ili LightGBM (zavisno da li je prioritet kalibracija ili prepoznavanje rjeđih ishoda) za Method cilj — Random Forest se ne preporučuje za Method cilj uprkos višoj accuracy.

## Zaključak i preporuke

Sistem uspješno predviđa UFC mečeve kroz dva odvojena cilja, s jasno različitim stepenom uspješnosti:

- **Winner** (60–63% tačnost, baseline 50%): predvidljiviji, pretežno linearan odnos — **Logistic Regression** preporučen izbor.

- **Method** (44–50% tačnost, baseline 47,7%): suštinski teži problem; accuracy sama zavarava — **Logistic Regression** ili **LightGBM** preporučeni umjesto Random Forest-a uprkos njegovoj višoj sirovoj accuracy, jer su znatno balansirani po klasama.
- **diff vs. concat**: reprezentacija featura (razlika vs. odvojene vrijednosti) ne donosi konzistentan dobitak ni za jedan model — postojeći diff pristup već je blizu optimalnog za ovaj skup podataka.

Glavni metodološki nalaz ovog rada jeste da tačnost (accuracy) sama po sebi nije dovoljna mjera uspješnosti modela u situacijama kada model treba biti koristan za sve klase ishoda, a ne samo za najčešću — macro-F1 i matrica konfuzije, odnosno recall po pojedinačnoj klasi, otkrivaju stvarnu upotrebljivost modela koju sama accuracy prikriva. Ovo je najočiglednije kod Random Forest modela na cilju Method, gdje accuracy iznad 50% prikriva činjenicu da model gotovo nikada ne prepozna ishod Submission.

### Preporuke za dalji rad:

- Dodati specifičnije feature za Submission ishod (npr. postotak pobjeda submissionom u karijeri, ne samo pokušaji)
- Ispitati zamjenu koreliranih featura ( `prior_fight_count` , `prior_wins` , `prior_losses` ) jednim izvedenim (npr. win rate)
- Formalno statistički testirati diff-vs-concat razlike (paired bootstrap / McNemar) prije donošenja zaključka o značajnosti
- Razmotriti vremenski (chronological) train/test split za realističniju procjenu buduće upotrebe